電力用変圧器 油温予測PoC報告書

～実運用における予防保全の価値検証～

2026・03・18（水）

畑中　崚佑

本資料のアジェンダ

1. 案件概要と技術検証の目的

2. EDAを通じて得られた示唆

3. 分析アプローチの設計と妥当性

4. モデル構築結果と精度評価

5. 限界・課題および今後の改善方針

6. クライアント様への質問事項

1. 案件概要と技術検証（PoC）の目的

現状の経験則による閾値監視から，
データ駆動型の「予防保全」への移行可能性を検証します．

検証データ：ETT (Electricity Transformer Temperature) データセット
・・・変圧器の負荷と油温がセットになった2年分のデータ

【現状の課題と悩み】

- 経験則に頼った単純な閾値監視
- 負荷変動や外部要因による温度変動の複雑化
- 異常発生後の「事後対応」が中心
- 突発的な温度上昇による設備劣化リスク
- 不必要な安全マージンによる運用ロス

【本PoCの目的と期待】

- 複数センサー（負荷電流等）による油温予測の精度検証
- モデルの妥当性評価
- 予測に基づく「予防保全」への移行可能性の立証
- 異常の早期検知による事故リスク低減
- 運用判断へのデータ駆動型示唆の提供

2. EDAを通じて得られた示唆

用いるデータセットの構造について.

今回は，ETTh1.csvのデータセットを用いて分析を実施しました.

以下のコラムが入っていました.

カラム名	物理的な意味	解釈
date	日時	データの記録時刻（1時間ごと）
HUFL	高圧側　最大負荷	変圧器の高圧側における最大負荷時の使用状況
HULL	高圧側　低負荷	変圧器の高圧側における低負荷時の使用状況
MUFL	中圧側　最大負荷	変圧器の中圧側における最大負荷時の使用状況
MULL	中圧側　低負荷	変圧器の中圧側における低負荷時の使用状況
LUFL	低圧側　最大負荷	変圧器の低圧側における最大負荷時の使用状況
LULL	低圧側　低負荷	変圧器の低圧側における低負荷時の使用状況
OT	**油温 (Oil Temperature)**	**ターゲット変数** （変圧器内部の絶縁油の温度）

2. EDAを通じて得られた示唆

油温は２４時間のスパンで周期性が見られる.

以下の図は, 時刻ごとの平均油温を示す.

- 油温は14時～17時ごろに頭打ちする傾向がある.
- 外気温や人間の生活リズムと関係性がある可能性.

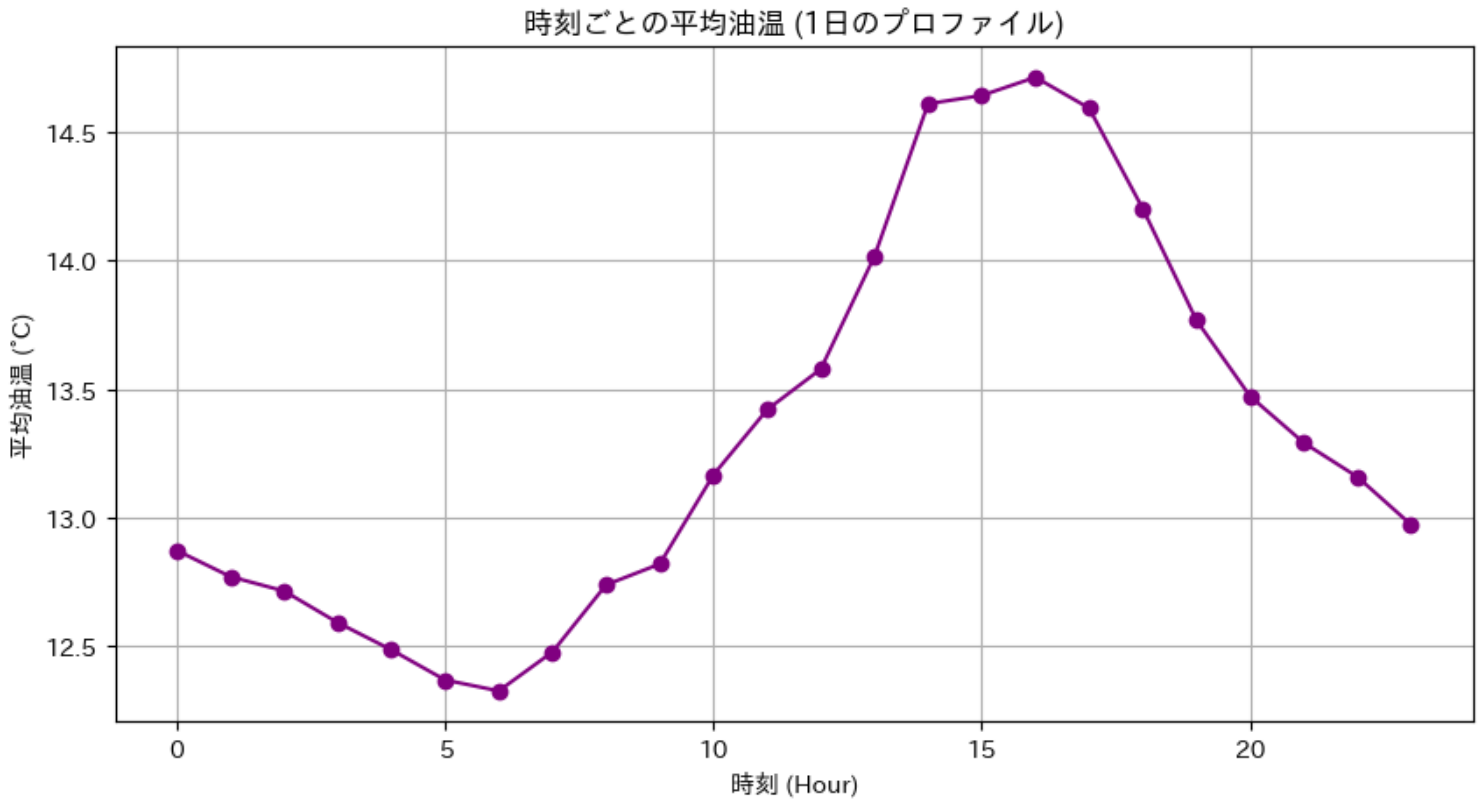

2. EDAを通じて得られた示唆

負荷と油温の間にも関係性が見られる.

- 負荷（主にHUFLやMUFL）が高まってから数時間後に油温も高まる傾向.
- 負荷が高いほど，その後の油温上昇も大きくなりやすい傾向.

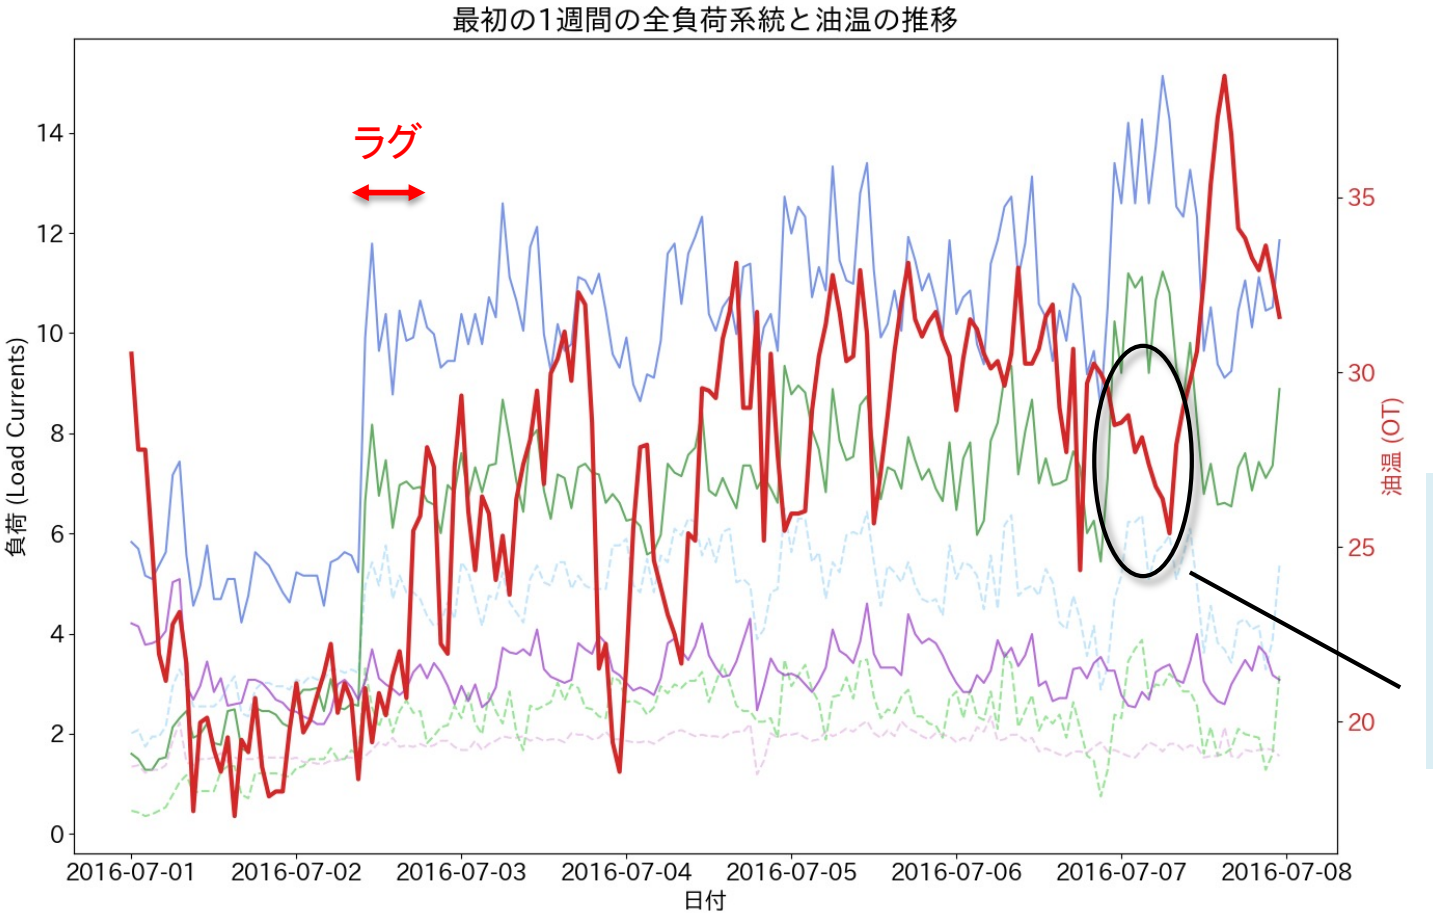

負荷が上昇した後に油温が下がるパターンもある.
外気温の低くなる未明に油温が冷やされた可能性.

2. EDAを通じて得られた示唆

長期的な油温の推移を見ると，季節と油温の関係性が考えられる.

- 夏季に油温が高くなる傾向がある.
- 一方で，年によってどれくらい油温が高まるのかは異なる.

→　長期においても負荷以外の温度変化要因がある可能性.　例）外気温

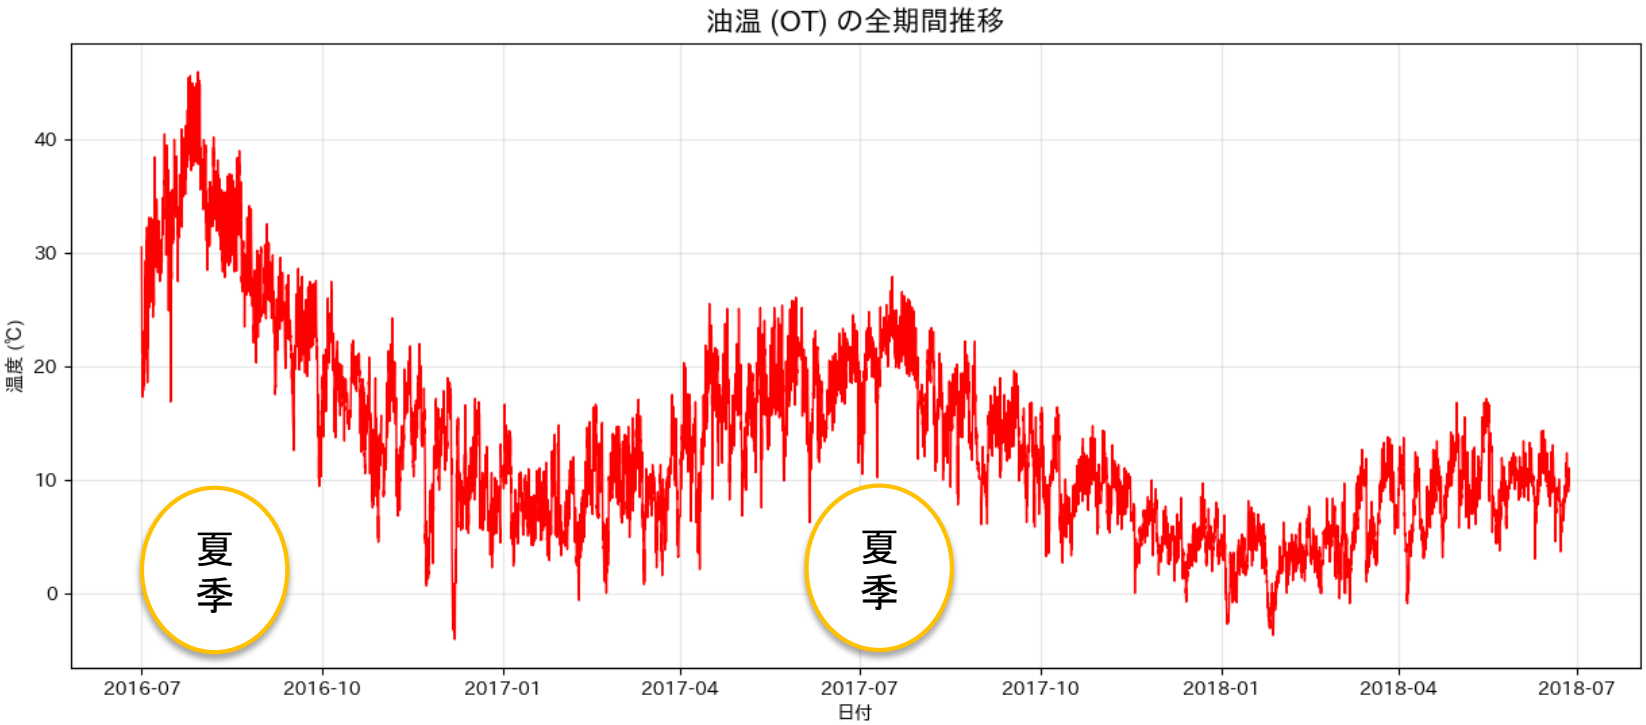

2. EDAを通じて得られた示唆

変数間の相関が強い組み合わせが存在しました.

相関の強い組み合わせ

- HUFLとMUFL（相関 0.99）
- HULLとMULL（相関 0.93）

モデル構築では両方とも説明変数に加えるが，結果の解釈時には相関に注意する.

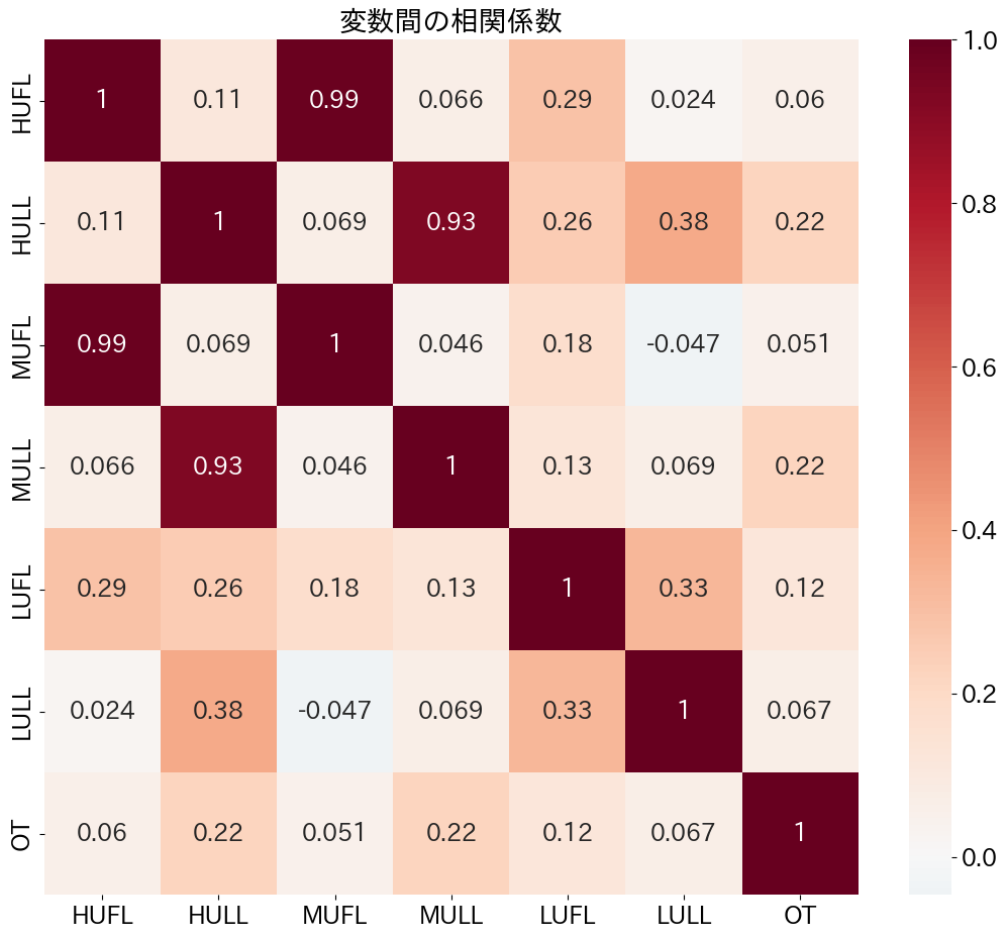

3. 分析アプローチの設計と妥当性

LSTMモデルを用いてアプローチしました.

LSTM（Long Short-Term Memory）モデルとは？

ニューラルネットワークの一種で，時系列データに特化したモデル.
長期間にわたる依存関係を捉えられるのが強み.

比較項目	従来モデル (RNN / 回帰)	LSTM モデル
時間的依存関係	入力データを「単なる数値の集合」として扱い，時系列の連続性を無視.	内部に「記憶セル (Cell State)」を保持．時系列順に情報を伝搬可能.
ラグ・時定数学習	時間遅れ(物理的遅延)を考慮するためにはラグ特徴量の手動設計が必要.	入力負荷から油温上昇までの「時差」を，モデル自らが学習によって獲得.
蓄熱効果の学習	直近の数値に過敏に反応しやすく，古い負荷の影響は急速に消失(勾配消失).	「忘却ゲート」により長期記憶を制御．スパイク後の蓄熱効果を持続的に保持.

3. 分析アプローチの設計と妥当性

分析フロー

1

データの「整理」と「特徴」の作成

・過去のデータ読込 (電力負荷・油温･時刻)
・学習を安定させるための標準化処理
・学習データ(80%)とテストデータ(20%)に分割

2

LSTMモデルによる「学習」

・過去２日間(４８時間)の連続した変化パターンを学習
・絶対温度ではなく「6時間前からの変化量」を予測対象に設定
・過学習を防ぐDropoutとEarlyStoppingの適用

3

予測の「評価」と「見える化」

・予測された変化量を実温度に復元し、誤差(MAE/RMSE)を評価
・寄与度分析により「何時間前のどの負荷が影響したか」をマップ化

3. 分析アプローチの設計と妥当性

用いる説明変数について

変数名	詳細説明
負荷量 HUFL,HULL,MUFL,MULL,LUFL,LULL	４８時間のスライディングウィンドウ方式でデータセットを構築．（シーケンスとも言う．） 各データがどのように予測に効くのかを見るため，全ての負荷変数を用いる．
時刻（１時間単位で０時～２４時）	１日の中での短期的な外気温の変化（昼間は気温が高い）などを考慮するために，時刻データを組み込む．
月	長期的な外気温の変化（夏季は気温が高い）などを考慮するために，測定した月を組み込む．

3. 分析アプローチの設計と妥当性

工夫にした点について

工夫点	理由
油温の絶対値ではなく， 変化量を予測した点．	モデルが長期的なトレンドに惑わされず，変動の要因（負荷の変化など）に集中できるようにするため． ※油温の絶対値を予測するモデルも作ってみたが，今回のデータセットのみでは精度を高めることができなかった．
過学習の防止	過学習（オーバーフィッティング）を自動で防ぎ，最も精度の高かった時点の重みを保持しています．
モデルの解釈性	ブラックボックスになりがちなLSTMモデルの中身を説明可能にし，クライアントに納得していただける成果にするため．

3. 分析アプローチの設計と妥当性

寄与度分析について

本モデルの課題点

今回のモデルは線形モデルではないため，ブラックボックス化してしまう.
・・・どんな変数がどのように結果に寄与しているのか分からない.

解決策

寄与度Sを右の式で定義した.

$$S_i = x_i \times \frac{\partial y}{\partial x_i}$$

$\frac{\partial y}{\partial x_i}$ は入力 x_i に対する出力 y の勾配（偏微分係数）

解析の手順は以下である.

① テストデータから任意にデータを100件抽出し，時間ごと特徴量ごとに勾配を計算する.
② 寄与度を算出する.
③ 全サンプルの寄与度を時間軸および特徴量ごとに平均化する.
④ ヒートマップとして可視化する.

4. モデル構築結果と精度評価

予測モデルはデータに潜む周期性を反映することができました.

下図は，テストデータの一部を実測と予測に分けてグラフにしたもの.
特に大きな油温変動はモデルで再現できていない.

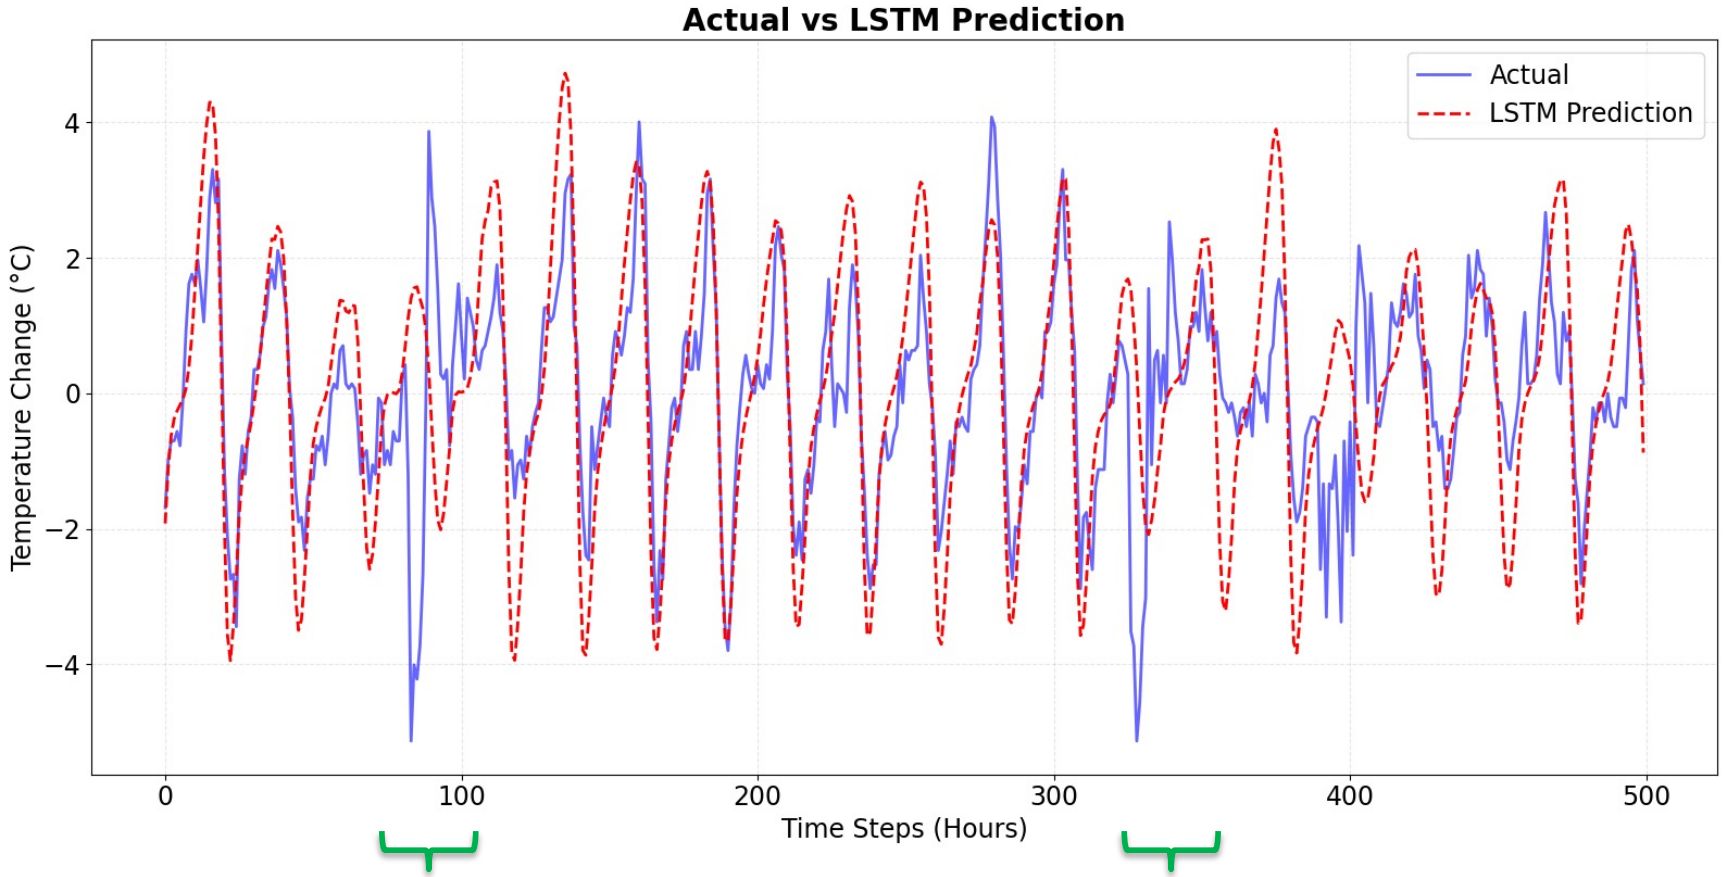

変動の大きな部分　　変動の大きな部分

4. モデル構築結果と精度評価

精度については更なる改善が望まれます.

評価指標

MAE	1.0141
RMSE	1.3918
R2 Score	0.2754

平均で1℃の誤差がありながらRMSEが約1.4のため，大きな油温の変動を的確に捉えられていない.
（全ページの推移グラフでも明らか）

予測値と実測値の分布　→

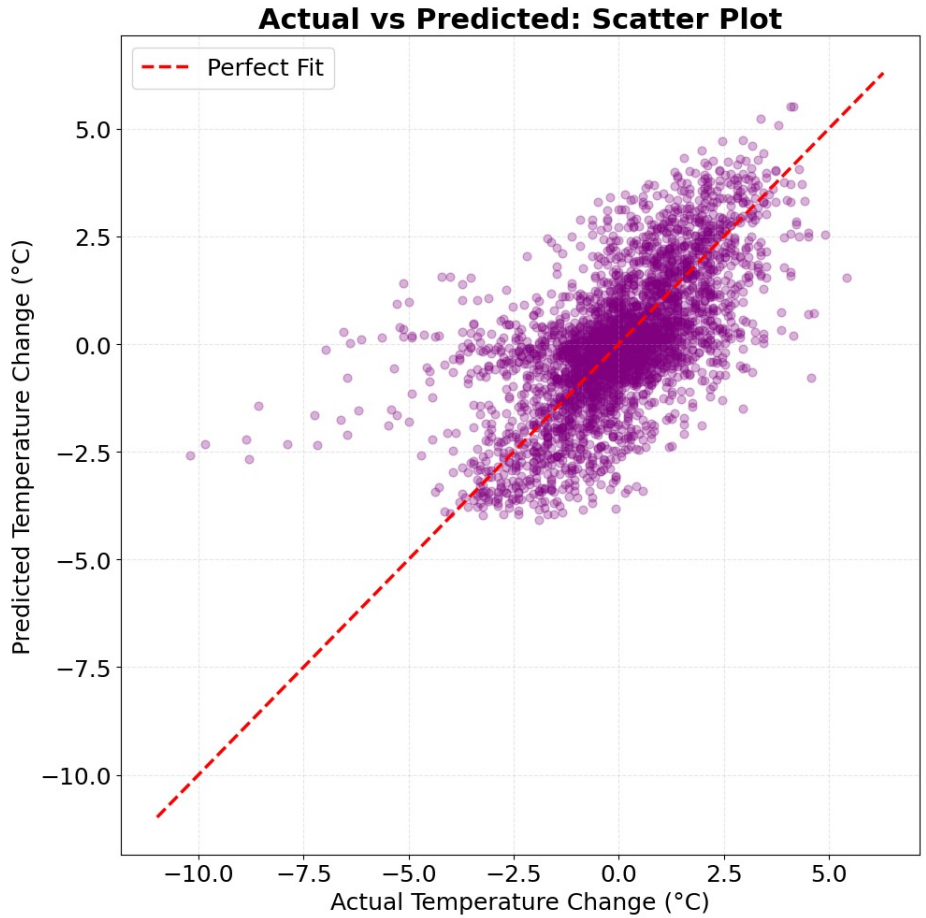

4. モデル構築結果と精度評価

油温の上昇に強く寄与する変数・タイムラグを突き止めることができました.

（寄与度分析結果）　赤色のエリア：変数の値が大きいほど予測値（油温）をプラスに動かす.
青色のエリア：変数の値が大きいほど予測値（油温）をマイナスに動かす.

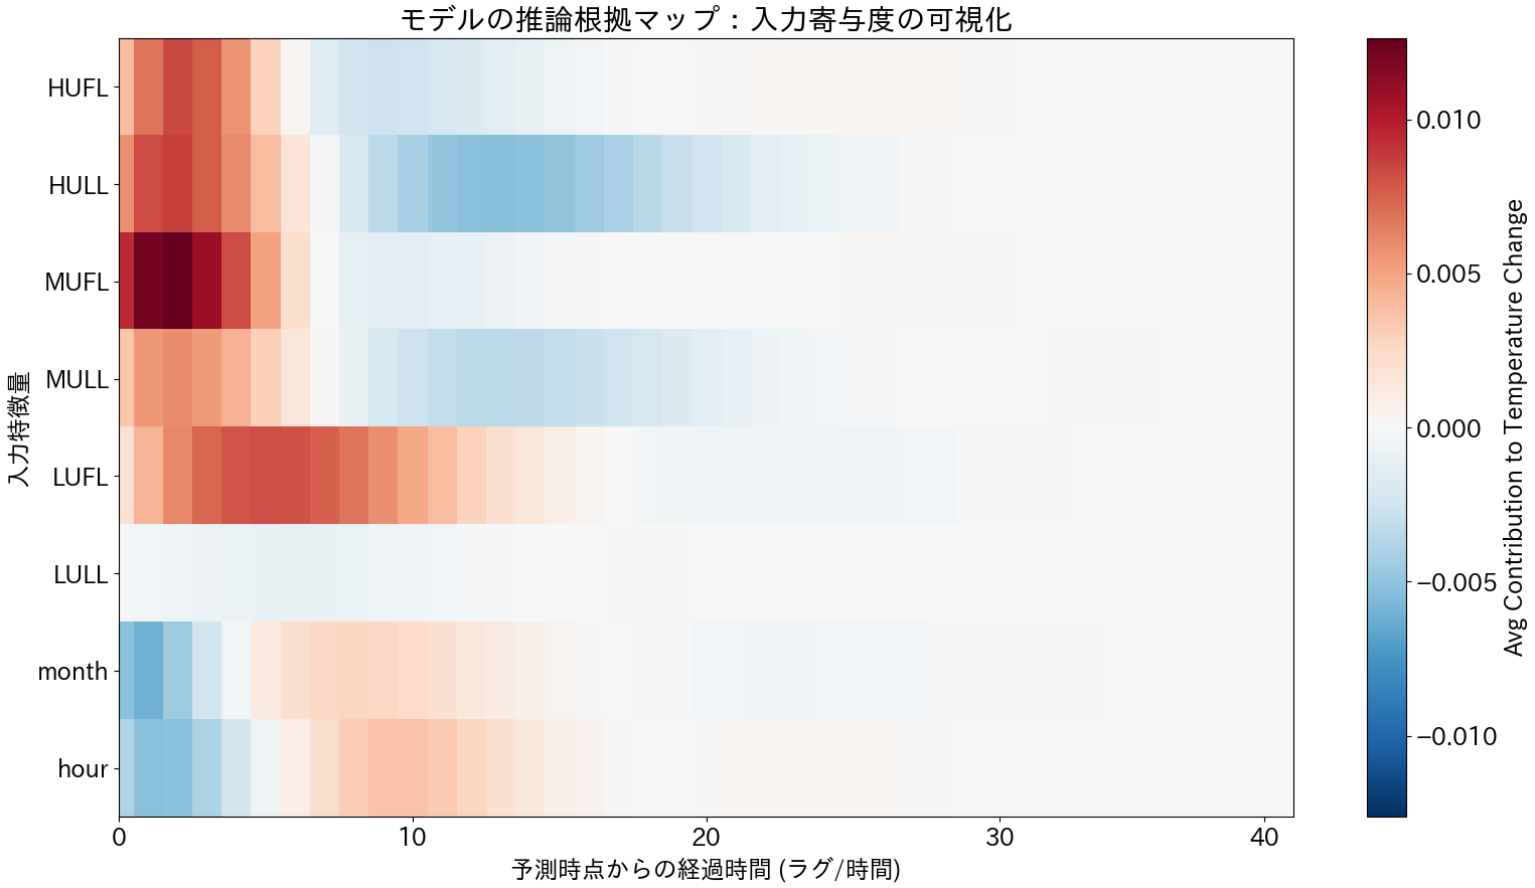

4. モデル構築結果と精度評価

油温の上昇に強く寄与する変数・タイムラグを突き止めることができました.

（寄与度分析結果）

① 直近6時間のMUFLの負荷値が油温の上昇に寄与している可能性がある.

② LUFLの負荷は長期的に油温の上昇に寄与する.

③ LULLの負荷は油温の上昇に寄与しない.

④ hour の図を見ると，深夜帯（0時～）は6時間前の時刻が18時～となるため，油温が低く抑えられる現象を捉えられている.

<u>今回の寄与度分析結果はどのように役立つか</u>

油温を抑制する際に優先的に負荷調整を行うべき変圧器や機器を論理的に選択する際に役立つ.

5. 限界・課題および今後の改善方針

限界・課題	今後の改善方針
外気温など気象条件を説明変数に組み込めていない.	変圧器が設置されている場所（または周辺）の気象データの記録があれば説明変数に組み込む.
モデルの転用可能性の検討.	今回はETTh1.csvのデータを用いてモデルを実装した. このモデルがETTh2.csvのデータに対しても適用可能かどうか分析する.
急激な油温の変動にモデルが適応できていない.	実データで見られる急激な油温の変動について，その原因や発生しやすい状況をクライアント様に質問する.
データの分割について，チューニングの精度を確認する際にテストデータを用いた.	データを 学習用 : チューニング用 : テスト用 = 7 : 1 : 2 のように 3分割する.

5. 限界・課題および今後の改善方針

負荷予測と油温予測モデルを融合し,
あらゆる変動に対応する真の運用最適化を目指します.

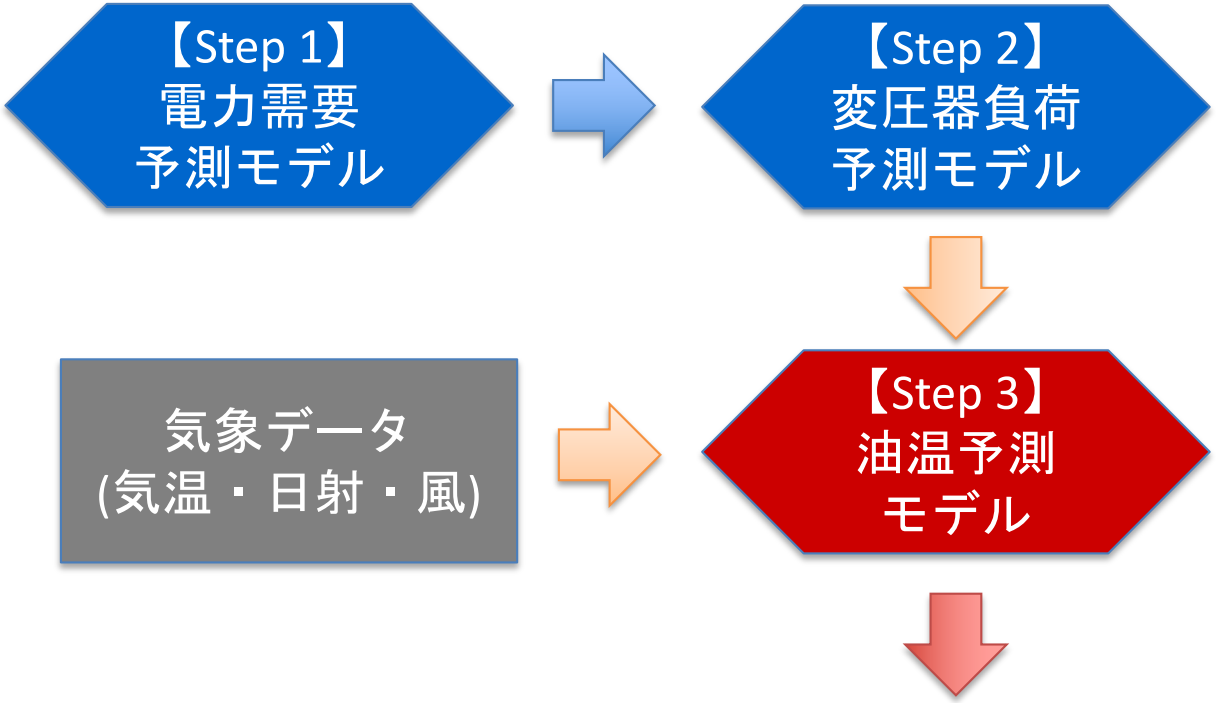

<u>リアルタイム監視による運用最適化</u>

①負荷投入の最適化:油温が上昇する前に負荷を別の変圧器に分散させる.

②省エネ運転:油温の上昇が予測されていない時間に冷却装置の稼働を抑える.

6. クライアント様に対する質問事項

実務で使えるモデルの作成や課題解決のため，お聞きしたいことがあります．

① モデルの予測では反映できなかった急激な温度変化について，現場で心当たりはありますか？（人為的介入など）
原因が分かればモデルに反映できる可能性があります．

② 変圧器の故障は，どれくらい油温が高くなると発生するのでしょうか．また，老朽化の程度によってそのリスクも異なるのでしょうか．

③ 今回は6時間での温度変化を予測するモデルを構築しましたが，いかがでしょうか．
目的に応じて予測スパンを柔軟に調整することも可能です．

予測時間の短縮（例：1～3時間先）	予測時間の延長（例：12～24時間先）
突発的な負荷変動に対するリアルタイムな監視性能を強化し，より即時性の高いアラート運用が可能になります．	翌日の運用計画（負荷投入スケジュール）の事前検証や，より余裕を持った保守点検計画の策定に寄与します．